

PROJEK UJIAN TENGAH SEMESTER
ANALITIK DAN VISUALISASI DATA
“ANALISIS DAN EDA STUDENT PERFORMANCE”



Disusun oleh:

Atha Rina Sarwahita (2509116047)

Program Studi Sistem Informasi

Fakultas Teknik

Universitas Mulawarman

2026

KATA PENGANTAR

Puji Syukur saya panjatkan kepada Tuhan Yang Maha Esa atas karunia yang telah di berikan-Nya dalam menyusun laporan Ujian Tengah Semester mata kuliah Analitik Visualisasi Data dengan judul tema “Analisis dan EDA Student Performance”, hingga saya dapat menyelesaikan ini tepat waktu tanpa halangan dan sesuai dengan harapan.

Ucapan terima kasih sebesar-besarnya saya berikan kepada dosen pengampu mata kuliah Analitik dan Visualisasi Data, yaitu Bapak Dr. Akhmad Irsyad S.T.,M.Kom. yang telah membimbing saya dalam pembuatan laporan ini.

Saya menyadari bahwa dalam penyusunan laporan ini masih banyak kekurangan karena keterbatasan saya. Maka dari itu saya sangat mengharapkan kritik dan saran untuk menyempurnakan laporan ini. Semoga apa yang dituliskan dapat bermanfaat bagi semua pihak yang membutuhkan.

Samarinda, 01 April 2026

DAFTAR ISI

KATA PENGANTAR.....	ii
DAFTAR ISI.....	iii
DAFTAR GAMBAR.....	iv
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang	1
1. 2 Tujuan Analisis	1
BAB II TAHAPAN ANALISIS.....	3
2.1 Business Understanding	3
2.2 Data Understanding.....	4
2.2.1 Import Library.....	4
2.2.2 Memuat dan Menampilkan Dataset	4
2.2.3 Struktur Data (Informasi Lanjutan).....	5
2.2.4 Statistik Deskriptif	5
2.2.5 Cek Inconsistent Values.....	6
2.2.6 Cek Missing Values	10
2.2.7 Cek Duplicated Values.....	10
2.2.8 Cek Outliers	11
2.3 Data Preparation.....	12
2.4 EDA	12
2.4.1 Comparison (Perbandingan)	12
2.4.2 Composition (Komposisi)	14
2.4.3 Distribution (Distribusi).....	15
2.4.4 Relationship (Hubungan)	16
BAB III PENUTUP	18
3.1 Kesimpulan	18
3.2 Saran.....	18

DAFTAR GAMBAR

Gambar 2. 1 Memuat dan Menampilkan Dataset	5
Gambar 2. 2 Struktur Data (Informasi Lanjutan).....	5
Gambar 2. 3 Statistik Deskriptif	6
Gambar 2. 4 Cek Inconsistent Value Kolom ‘Student_id’	7
Gambar 2. 5 Cek Inconsistent Value Kolom ‘gender’	7
Gambar 2. 6 Cek Inconsistent Value Kolom ‘age’	7
Gambar 2. 7 Cek Inconsistent Value Kolom ‘study_hours_per_week’	8
Gambar 2. 8 Cek Inconsistent Value Kolom ‘attendance_rate’	8
Gambar 2. 9 Cek Inconsistent Value Kolom ‘parent_education’	8
Gambar 2. 10 Cek Inconsistent Value Kolom ‘internet_access’	9
Gambar 2. 11 Cek Inconsistent Value Kolom ‘extracurricular’	9
Gambar 2. 12 Cek Inconsistent Value Kolom ‘previous_score’	9
Gambar 2. 13 Cek Inconsistent Value Kolom ‘final_score’	9
Gambar 2. 14 Cek Inconsistent Value Kolom ‘passed’	9
Gambar 2. 15 Cek Missing Value	10
Gambar 2. 16 Cek Duplicated Values.....	10
Gambar 2. 17 Cek Outliers	11
Gambar 2. 18 Comparison (Perbandingan).....	13
Gambar 2. 19 Composition (Komposisi)	14
Gambar 2. 20 Distribution (Distribusi)	15
Gambar 2. 21 Relationship (Hubungan)	16

BAB I

PENDAHULUAN

1.1 Latar Belakang

Pendidikan merupakan fondasi utama dalam pembentukan kualitas sumber daya manusia. Salah satu indikator keberhasilan proses pendidikan yang paling mudah diukur adalah performa akademik siswa, yang tercermin dari nilai ujian dan status kelulusan. Namun, performa akademik bukanlah hasil dari satu faktor tunggal, ia merupakan produk dari interaksi berbagai variabel yang saling memengaruhi, baik yang bersifat internal maupun eksternal.

Faktor internal mencakup kebiasaan dan intensitas belajar siswa, sedangkan faktor eksternal meliputi tingkat kehadiran, latar belakang pendidikan orang tua, kondisi ekonomi keluarga, hingga ketersediaan fasilitas penunjang seperti akses internet. Kompleksitas hubungan antar faktor ini seringkali menyulitkan institusi pendidikan dalam menentukan prioritas intervensi yang paling efektif, terutama bagi siswa yang berisiko tidak mencapai kelulusan.

Di sinilah pendekatan berbasis data menjadi relevan. Dengan memanfaatkan teknik Exploratory Data Analysis (EDA), pola-pola yang tersembunyi dalam data dapat digali secara sistematis dan objektif. Hasilnya dapat menjadi dasar pengambilan keputusan yang lebih tepat sasaran, baik oleh pengajar, konselor akademik, maupun pihak manajemen sekolah dalam merancang program peningkatan kualitas belajar siswa.

Penelitian ini menganalisis dataset yang memuat rekam jejak 500 siswa dengan 11 variabel, mencakup karakteristik demografis, kebiasaan belajar, kondisi lingkungan, serta hasil akademik. Melalui pendekatan EDA, penelitian ini berupaya memberikan gambaran menyeluruh mengenai faktor-faktor yang paling memengaruhi nilai akhir dan status kelulusan siswa.

1.2 Tujuan Analisis

Analisis ini bertujuan untuk mengeksplorasi faktor-faktor yang memengaruhi performa akademik siswa, khususnya nilai akhir (final score) dan status kelulusan (passed). Melalui berbagai tahapan analisis data sampai tahap Exploratory Data Analysis (EDA), analisis ini mencoba menjawab pertanyaan-pertanyaan berikut.

1. Faktor apa yang paling kuat berkorelasi dengan nilai akhir siswa?
2. Apakah jam belajar per minggu berpengaruh signifikan terhadap kelulusan?
3. Bagaimana distribusi nilai akhir secara keseluruhan?

4. Apakah latar belakang pendidikan orang tua, akses internet, dan keikutsertaan ekstrakurikuler memengaruhi hasil belajar?

BAB II

TAHAPAN ANALISIS

2.1 Business Understanding

2.1.1 Business Objective

Dataset Student Performance digunakan untuk memahami keterkaitan antara berbagai faktor latar belakang dan kebiasaan belajar siswa dengan hasil akademik mereka. Faktor-faktor seperti jam belajar per minggu, tingkat kehadiran, pendidikan orang tua, akses internet, keikutsertaan dalam ekstrakurikuler, hingga nilai sebelumnya menjadi variabel penting yang dianalisis karena berpotensi memengaruhi nilai akhir dan status kelulusan siswa secara langsung maupun tidak langsung.

Analisis ini bertujuan untuk mengidentifikasi faktor dominan yang berkontribusi terhadap keberhasilan akademik siswa, khususnya dalam hal pencapaian nilai akhir (final score) dan status lulus atau tidak lulus (passed). Dengan memahami pola dan hubungan antar variabel tersebut, hasil analisis diharapkan dapat memberikan landasan yang kuat bagi institusi pendidikan dalam merancang program intervensi yang lebih tepat sasaran, terutama bagi siswa yang berisiko tinggi tidak lulus.

Insight yang diperoleh dari analisis ini diharapkan dapat dimanfaatkan untuk mendukung pengambilan keputusan berbasis data dalam bidang pendidikan, mulai dari penyusunan kebijakan belajar, alokasi sumber daya, hingga program pendampingan siswa.

2.1.2 Assess Situation

Tahap awal analisis dimulai dengan meninjau kondisi dataset yang digunakan, yaitu `student_performance.csv`. Dataset ini memuat rekam jejak 500 siswa dengan 11 variabel.

Data yang tersedia cukup beragam sehingga memungkinkan eksplorasi hubungan multivariabel. Namun demikian, terdapat beberapa hal yang perlu diperhatikan dalam proses analisis. Oleh karena itu, tahap pembersihan dan eksplorasi data menjadi langkah krusial agar seluruh hasil analisis tetap valid, dapat diinterpretasikan, dan dapat dipercaya.

2.1.3 Analytic Goals & Project Plan

Fokus utama analisis ini adalah:

1. Faktor apa yang paling kuat berkorelasi dengan nilai akhir siswa?
2. Apakah jam belajar per minggu berpengaruh signifikan terhadap kelulusan?
3. Bagaimana distribusi nilai akhir secara keseluruhan?

4. Apakah pendidikan orang tua, akses internet, dan ekstrakurikuler memengaruhi hasil belajar?

Rencana pengerjaan analisis ini disusun dalam empat tahap berurutan.

1. Tahap pertama adalah persiapan dan pembersihan data, yang mencakup pemeriksaan nilai hilang, deteksi duplikasi, serta validasi tipe dan rentang nilai setiap variabel.
2. Tahap kedua adalah analisis deskriptif, di mana statistik dasar seperti rata-rata, median, dan standar deviasi dihitung untuk memahami pola umum dalam dataset.
3. Tahap ketiga adalah Exploratory Data Analysis (EDA), yang mencakup visualisasi distribusi, analisis korelasi, serta perbandingan antar kelompok untuk menemukan pola dan hubungan antar variabel.
4. Tahap keempat adalah penarikan insight dan rekomendasi, di mana setiap temuan dari EDA akan diinterpretasikan dan diterjemahkan menjadi rekomendasi yang dapat digunakan oleh institusi pendidikan sebagai dasar intervensi berbasis data.

2.2 Data Understanding

2.2.1 Import Library

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
```

Saya mengimport 3 *library* pada analisis ini, yaitu dengan fungsi sebagai berikut:


- Pandas, untuk membaca dan menuklis data dari berbagai format (CSV, Excel, SQL, JSON)
- Matplotlib, untuk menciptakan berbagai jenis grafik (bar chart, line chart, scatter)
- Seaborn, untuk menghasilkan visualisasi yang lebih estetik dan modern

2.2.2 Memuat dan Menampilkan Dataset

```
from google.colab import drive
drive.mount('/content/drive')
path = '/content/drive/MyDrive/UTS AVD/student_performance.csv'
df = pd.read_csv(path)
df
```

Pada tahap ini, saya memuat dan menampilkan dataset. Saya meng-import dataset dari google drive dan menyalin path (jalur) dari google drive. Lalu, kami

menggunakan kode untuk membaca dan menampilkan variable menggunakan 'df'. Output dari kode di atas adalah sebagai berikut:



	student_id	gender	age	study_hours_per_week	attendance_rate	parent_education	internet_access	extracurricular	previous_score	final_score	passed
0	STU0001	Male	15	25	63.8	Bachelor	Yes	Yes	41	67	Yes
1	STU0002	Female	15	2	54.7	Bachelor	Yes	Yes	83	28	No
2	STU0003	Female	19	10	90.5	High School	Yes	No	73	49	No
3	STU0004	Male	16	26	66.8	High School	No	Yes	75	70	Yes
4	STU0005	Female	15	25	73.0	High School	No	Yes	67	77	Yes
...	...	...	...	...	...	...	...	...	...	...	...
495	STU0496	Female	19	6	78.3	Master	No	No	51	27	No
496	STU0497	Female	16	27	61.1	PhD	No	No	47	74	Yes
497	STU0498	Female	18	16	72.3	Master	No	Yes	52	61	Yes
498	STU0499	Male	17	29	91.3	NaN	Yes	No	39	86	Yes
499	STU0500	Male	15	29	75.4	High School	No	Yes	34	74	Yes

500 rows x 11 columns

Gambar 2. 1 Memuat dan Menampilkan Dataset

Dapat terlihat bahwa dataset sudah tertampil dari baris data ke satu sampai ke 500 dan dapat terlihat juga bahwa dataset memiliki 11 kolom.

2.2.3 Struktur Data (Informasi Lanjutan)

```
df.info()
```

Pada tahap ini, saya menggunakan kode yang bertujuan untuk menampilkan informasi struktur data, ini merupakan informasi lanjutan dari dataset. Output yang dihasilkan kode di atas adalah sebagai berikut:

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 500 entries, 0 to 499
Data columns (total 11 columns):
 #   Column                Non-Null Count  Dtype
---  -
 0   student_id            500 non-null    object
 1   gender                 500 non-null    object
 2   age                   500 non-null    int64
 3   study_hours_per_week  500 non-null    int64
 4   attendance_rate        500 non-null    float64
 5   parent_education      383 non-null    object
 6   internet_access        500 non-null    object
 7   extracurricular        500 non-null    object
 8   previous_score         500 non-null    int64
 9   final_score            500 non-null    int64
10   passed                500 non-null    object
dtypes: float64(1), int64(4), object(6)
memory usage: 43.1+ KB
```


Gambar 2. 2 Struktur Data (Informasi Lanjutan)

Dapat terlihat pada gambar output di bawah bahwa dataset ini memiliki 500 Baris dan 11 Kolom. Dapat terlihat pula informasi lanjutan pada setiap kolom, yaitu berupa jumlah baris dan tipe data.

2.2.4 Statistik Deskriptif

```
df.describe()
```

Statistik Deskriptif di sini ditampilkan menggunakan kode di atas yang bertujuan untuk menampilkan angka statistik pada masing-masing kolom. Data yang tercantum seperti mean, median, modus, nilai minimal, nilai maksimal, dan standar deviasi. Output dari kode di atas adalah sebagai berikut:



	age	study_hours_per_week	attendance_rate	previous_score	final_score
count	500.000000	500.000000	500.000000	500.000000	500.000000
mean	16.978000	15.312000	76.380600	62.986000	55.980000
std	1.434445	8.568167	13.817681	18.937451	15.373754
min	15.000000	2.000000	50.200000	30.000000	20.000000
25%	16.000000	8.000000	64.475000	46.000000	45.000000
50%	17.000000	15.000000	76.500000	64.000000	56.000000
75%	18.000000	23.000000	88.525000	79.000000	68.000000
max	19.000000	30.000000	100.000000	95.000000	95.000000

Gambar 2. 3 Statistik Deskriptif

Pada hasil pengecekan statistik deskriptif di atas, dapat terlihat bahwa:

- Rata-rata usia siswa adalah 16,98 tahun, dengan rentang 15–19 tahun. ini menunjukkan bahwa dataset merepresentasikan siswa tingkat menengah atas.
- Rata-rata jam belajar per minggu adalah 15,31 jam dengan standar deviasi yang cukup tinggi (8,57), mengindikasikan variasi kebiasaan belajar yang signifikan antar siswa.
- Rata-rata nilai akhir sebesar 55,98 (dari skala 100), sedikit di atas ambang lulus, dengan distribusi cukup merata antara nilai rendah dan tinggi.
- Nilai previous score rata-rata 62,99, sedikit lebih tinggi dari final score, yang dapat mengindikasikan penurunan performa secara keseluruhan pada ujian akhir.

2.2.5 Cek Inconsistent Values

```
print(df['student_id'].unique())
print(df['gender'].unique())
print(df['age'].unique())
print(df['study_hours_per_week'].unique())
print(df['attendance_rate'].unique())
print(df['parent_education'].unique())
print(df['internet_access'].unique())
print(df['extracurricular'].unique())
```

```
print(df['previous_score'].unique())
print(df['final_score'].unique())
print(df['passed'].unique())
```

Di sini saya mengecek *inconsistent value* pada dataset untuk mengetahui apakah penulisan dari kategori atau numerik pada dataset sudah konsisten atau belum. Saya menggunakan kode “`print(df[‘nama_kolom’].unique())`” untuk menampilkan apakah ada data unik pada kolom tersebut. Hasil masing-masing dari kode di atas beserta insight yang saya dapatkan adalah sebagai berikut:

```
1. Student ID

print(df['student_id'].unique())

['STU0001' 'STU0002' 'STU0003' 'STU0004' 'STU0005' 'STU0006' 'STU0007'
 'STU0008' 'STU0009' 'STU0010' 'STU0011' 'STU0012' 'STU0013' 'STU0014'
 'STU0015' 'STU0016' 'STU0017' 'STU0018' 'STU0019' 'STU0020' 'STU0021'
 'STU0022' 'STU0023' 'STU0024' 'STU0025' 'STU0026' 'STU0027' 'STU0028'
 'STU0029' 'STU0030' 'STU0031' 'STU0032' 'STU0033' 'STU0034' 'STU0035'
 'STU0036' 'STU0037' 'STU0038' 'STU0039' 'STU0040' 'STU0041' 'STU0042'
 'STU0043' 'STU0044' 'STU0045' 'STU0046' 'STU0047' 'STU0048' 'STU0049'
 'STU0050' 'STU0051' 'STU0052' 'STU0053' 'STU0054' 'STU0055' 'STU0056'
 'STU0057' 'STU0058' 'STU0059' 'STU0060' 'STU0061' 'STU0062' 'STU0063'
 'STU0064' 'STU0065' 'STU0066' 'STU0067' 'STU0068' 'STU0069' 'STU0070'
 'STU0071' 'STU0072' 'STU0073' 'STU0074' 'STU0075' 'STU0076' 'STU0077'
 'STU0078' 'STU0079' 'STU0080' 'STU0081' 'STU0082' 'STU0083' 'STU0084'
 'STU0085' 'STU0086' 'STU0087' 'STU0088' 'STU0089' 'STU0090' 'STU0091'
 'STU0092' 'STU0093' 'STU0094' 'STU0095' 'STU0096' 'STU0097' 'STU0098'
 'STU0099' 'STU0100' 'STU0101' 'STU0102' 'STU0103' 'STU0104' 'STU0105'
 'STU0106' 'STU0107' 'STU0108' 'STU0109' 'STU0110' 'STU0111' 'STU0112'
 'STU0113' 'STU0114' 'STU0115' 'STU0116' 'STU0117' 'STU0118' 'STU0119'
 'STU0120' 'STU0121' 'STU0122' 'STU0123' 'STU0124' 'STU0125' 'STU0126'
 'STU0127' 'STU0128' 'STU0129' 'STU0130' 'STU0131' 'STU0132' 'STU0133'
 'STU0134' 'STU0135' 'STU0136' 'STU0137' 'STU0138' 'STU0139' 'STU0140'
 'STU0141' 'STU0142' 'STU0143' 'STU0144' 'STU0145' 'STU0146' 'STU0147'
 'STU0148' 'STU0149' 'STU0150' 'STU0151' 'STU0152' 'STU0153' 'STU0154'
 'STU0155' 'STU0156' 'STU0157' 'STU0158' 'STU0159' 'STU0160' 'STU0161'
 'STU0162' 'STU0163' 'STU0164' 'STU0165' 'STU0166' 'STU0167' 'STU0168'
 'STU0169' 'STU0170' 'STU0171' 'STU0172' 'STU0173' 'STU0174' 'STU0175'
 'STU0176' 'STU0177' 'STU0178' 'STU0179' 'STU0180' 'STU0181' 'STU0182'
 'STU0183' 'STU0184' 'STU0185' 'STU0186' 'STU0187' 'STU0188' 'STU0189'
 'STU0190' 'STU0191' 'STU0192' 'STU0193' 'STU0194' 'STU0195' 'STU0196'
 'STU0197' 'STU0198' 'STU0199' 'STU0200' 'STU0201' 'STU0202' 'STU0203']
```

Gambar 2. 4 Cek Inconsistent Value Kolom ‘Student_id’

Kolom Student_id sudah konsisten karena hanya berisi nomor unik danurut. Tidak ditemukan variasi penulisan yang bermasalah.

```
2. Gender

print(df['gender'].unique())

['Male' 'Female']
```

Gambar 2. 5 Cek Inconsistent Value Kolom ‘gender’

Kolom Gender sudah konsisten dengan hanya dua kategori: ‘Male’ dan ‘Female’. Tidak ditemukan variasi penulisan yang bermasalah.

```
3. Age

print(df['age'].unique())

[15 19 16 18 17]
```

Gambar 2. 6 Cek Inconsistent Value Kolom ‘age’

Kolom Age sudah konsisten. Tidak ditemukan variasi penulisan dan nilai ekstrem.

```
4. Study Hours Per Week

print(df['study_hours_per_week'].unique())

[25  2 10 26  8 21  9 18  4 13 30 19 29 20 15  7 14 12 28  3 11 22 23 27
 24  6  5 16 17]
```

Gambar 2. 7 Cek Inconsistent Value Kolom ‘study_hours_per_week’

Kolom study_hours_per_week sudah konsisten. Tidak ditemukan variasi penulisan yang bermasalah.

```
5. Attendance Rate

print(df['attendance_rate'].unique())

[ 63.8  54.7  90.5  66.8  73.  85.2  72.7  81.7  84.2  95.7  57.  74.7
 69.2  63.3  93.8  88.1  99.3  74.3  93.6  75.9  61.5  66.5  73.6  70.6
 59.6  93.7  92.4  68.9  64.8  76.6  56.  83.5  96.5  56.6  77.2  55.4
 84.4  50.2  55.6  68.2  78.  59.  51.9  51.2  75.5  78.8  53.5  70.1
 78.5  82.7  54.2  60.  94.3  62.5  90.8  87.6  63.6  60.7  71.  69.5
 69.4  78.2  69.  97.6  82.5  73.7  80.4  83.9  88.6  75.3  94.6  96.
 94.1  74.4  75.8  85.6  83.2  87.1  59.7  98.7  73.5  53.3  55.9  65.3
 54.1  79.7  91.3  73.4  79.9  97.5  99.8  99.4  74.9  94.  50.7  96.6
 57.2  75.4  67.3  61.7  89.6  92.3  89.1  85.9  54.5  66.2  62.  83.3
 81.9  61.9  78.3  59.5  93.5  90.2  83.6  81.  70.4  94.4  86.3  72.2
 66.7  88.7  83.1  50.8  72.4  72.9  95.5  85.1  84.3  86.9  95.8  74.1
 90.4  67.6  76.5  52.7  91.7  93.1  98.3  79.4  89.  57.3  72.1  72.6
 97.9  85.4  66.9  69.3  98.4  56.4  80.5  70.9  96.7  95.3  65.9  91.6
 57.5  62.1  70.8  86.6  60.1  62.7  90.  80.1  99.9  56.9  59.3  94.9
 64.5  99.2  88.5  84.  57.7  59.8  58.4  52.3  81.4  53.6  80.3  55.3
 52.5  58.  68.3  64.4  89.7  83.8  78.7  91.4  76.8  96.8  83.7  61.8
 83.4  87.4  87.7  77.4  60.3  75.7  82.1  98.2  86.4  91.2  72.3  76.2
 68.6  96.9  88.8  78.1  91.1  59.2  80.9  95.9  52.8  96.2  92.5  80.7
 61.4  63.5  63.4  56.8  71.5  58.9  64.  97.7  75.  72.5  89.5  80.6
 61.1  67.4  85.5  77.6  82.  59.9  84.7  92.1  87.8  100.  93.3  78.9
 87.5  98.6  66.1  55.  54.6  76.  69.1  86.1  56.2  82.2  82.3  76.4
 84.1  96.1  62.2  56.3  53.2  93.  77.7  73.2  61.6  63.  97.2  70.3
 62.4  92.7  53.1  62.9  80.8  61.  99.6  57.4  99.1  74.  97.1  71.7
 96.3  78.6  64.6  94.7  57.6  92.  95.1  66.  79.1  73.8  92.6  72.8
 51.5  91.9  93.2  73.3  66.3  92.9  85.7  64.7  67.8  64.9  81.6  74.5
 86.7  55.8  85.  74.8  91.8  90.7  51.4  63.1  87.3  80.2  88.  68.7
 87.9  86.5  51.3  93.4  98.1  56.5  96.4  76.9  95.2  77.  70.2  57.8
 69.7  59.1]
```

Gambar 2. 8 Cek Inconsistent Value Kolom ‘attendance_rate’

Kolom attendance_rate sudah konsisten. Tidak ditemukan variasi penulisan yang bermasalah dan nilai ekstrem.

```
6. Parent Education

print(df['parent_education'].unique())

['Bachelor' 'High School' 'Master' nan 'PhD']
```

Gambar 2. 9 Cek Inconsistent Value Kolom ‘parent_education’

Kolom parent_education sudah konsisten. Tidak ditemukan variasi penulisan yang bermasalah. Namun masih terdapat nilai kosong ‘nan’.

```

7. Internet Access

print(df['internet_access'].unique())

['Yes' 'No']

```

Gambar 2. 10 Cek Inconsistent Value Kolom 'internet_access'

Kolom internet_access sudah konsisten dengan hanya 2 respon: Yes dan No. Tidak ditemukan variasi penulisan yang bermasalah.

```

8. Extracurricular

print(df['extracurricular'].unique())

['Yes' 'No']

```

Gambar 2. 11 Cek Inconsistent Value Kolom 'extracurricular'

Kolom extracurricular sudah konsisten dengan hanya 2 respon: Yes dan No. Tidak ditemukan variasi penulisan yang bermasalah.

```

9. Previous Score

print(df['previous_score'].unique())

[41 83 73 75 67 40 89 70 93 81 50 31 85 68 92 60 90 69 38 37 42 84 36 91
 66 80 77 43 86 48 61 64 88 65 44 30 57 52 49 58 46 47 55 62 39 74 82 45
 87 56 94 33 71 51 59 35 54 95 79 32 63 76 53 78 34 72]

```

Gambar 2. 12 Cek Inconsistent Value Kolom 'previous_score'

Kolom previous_score sudah konsisten. Tidak ditemukan variasi penulisan yang bermasalah atau nilai ekstrem.

```

10. Final Score

print(df['final_score'].unique())

[67 28 49 70 77 37 42 56 44 69 38 64 84 89 79 65 46 72 48 53 75 24 78 43
 41 62 31 27 55 82 23 57 61 59 68 80 66 71 76 34 52 74 58 40 45 60 50 54
 51 32 39 63 29 22 47 73 33 20 36 81 91 26 35 85 30 21 95 93 83 86]

```

Gambar 2. 13 Cek Inconsistent Value Kolom 'final_score'

Kolom final_score sudah konsisten. Tidak ditemukan variasi penulisan yang bermasalah atau nilai ekstrem.

```

11. Passed

print(df['passed'].unique())

['Yes' 'No']

```


Gambar 2. 14 Cek Inconsistent Value Kolom 'passed'

Kolom passed sudah konsisten dengan hanya 2 respon: Yes dan No. Tidak ditemukan variasi penulisan yang bermasalah.

2.2.6 Cek Missing Values

```
pd.DataFrame(df.isna().sum() / len(df) * 100, columns=['Null Ratio in %'])
```

Pada tahap ini, saya mengecek apakah ada nilai data yang hilang atau *missing values*. Pada kode, saya ingin menampilkan missing value pada rasio persen, menggunakan kode '*Null Ratio in %*'. Output dari kode di atas adalah sebagai berikut:



	Null Ratio in %
student_id	0.0
gender	0.0
age	0.0
study_hours_per_week	0.0
attendance_rate	0.0
parent_education	23.4
internet_access	0.0
extracurricular	0.0
previous_score	0.0
final_score	0.0
passed	0.0

Gambar 2. 15 Cek Missing Value

Dari hasil pengecekan kolom-kolom, ditemukan missing values pada kolom *parent_education* sebesar 23.4%. Perlu dilakukan penanganan pada missing value terlebih dahulu agar tidak menghasilkan kesimpulan yang bias atau tidak akurat.

2.2.7 Cek Duplicated Values

```
df[df.duplicated()]
```

Di sini saya mengecek apakah terdapat nilai duplikat pada dataset. Output dari kode di atas adalah sebagai berikut:

```
student_id  gender  age  study_hours_per_week  attendance_rate  parent_education  internet_access  extracurricular  previous_score  final_score  passed
```

Gambar 2. 16 Cek Duplicated Values

Berdasarkan hasil pengecekan, tidak ditemukan data yang duplikat dalam dataset. Hal ini menunjukkan bahwa setiap baris merepresentasikan satu responden yang unik dan tidak ada pengulangan data yang sama secara keseluruhan.

2.2.8 Cek Outliers

```
results = []


# Exclude 'object' type columns for outlier detection using IQR
cols_numeric = df.select_dtypes(include=['float64', 'int64']).columns

for col in cols_numeric: # Iterate only over numeric columns
    q1 = df[col].quantile(0.25)
    q3 = df[col].quantile(0.75)
    iqr = q3 - q1
    lower_bound = q1 - 1.5*iqr
    upper_bound = q3 + 1.5*iqr
    outliers = df[(df[col] < lower_bound) | (df[col] > upper_bound)]
    percent_outliers = (len(outliers)/len(df))*100
    results.append({'Kolom': col, 'Persentase Outliers': percent_outliers})

# Dataframe dari list hasil
results_df = pd.DataFrame(results)
results_df.set_index('Kolom', inplace=True)
results_df = results_df.rename_axis(None, axis=0).rename_axis('Kolom', axis=1)

# Tampilkan dataframe
display(results_df)
```

Di sini saya mengecek apakah terdapat outliers (nilai ekstrem) yang terdapat pada dataset. Output dari kode di atas adalah sebagai berikut:



Kolom	Persentase Outliers
age	0.0
study_hours_per_week	0.0
attendance_rate	0.0
previous_score	0.0
final_score	0.0

Gambar 2. 17 Cek Outliers

Pada pengecekan outliers, tidak terdapat outliers pada kolom numerik. Sehingga tidak tercatat adanya data dengan nilai yang ekstrem atau kesalahan pengisian data.

2.3 Data Preparation

```
df['parent_education'] = df['parent_education'].fillna('Unknown')
```

Saya menangani *missing value* dengan perintah imputasi kolom menggunakan "Unknown", karena *missing value* yang terdapat pada kolom Parent education bermakna data tidak terisi sehingga tidak diketahui riwayat pendidikan dari orang tua murid.

Null Ratio in %	
student_id	0.0
gender	0.0
age	0.0
study_hours_per_week	0.0
attendance_rate	0.0
parent_education	0.0
internet_access	0.0
extracurricular	0.0
previous_score	0.0
final_score	0.0
passed	0.0

Dapat terlihat di atas bahwa missing value sudah berhasil ditangani.

2.4 EDA

2.4.1 Comparison (Perbandingan)

```
fig, axes = plt.subplots(1, 3, figsize=(16, 5))
fig.suptitle('Rata-rata Final Score berdasarkan Faktor Kategorikal', fontsize=14)

# 1. Gender
df.groupby('gender')['final_score'].mean().plot(kind='bar', ax=axes[0],
color=['#FF9999', '#66B2FF'], edgecolor='black')
axes[0].set_title('Final Score by Gender')
axes[0].set_ylabel('Rata-rata Final Score')
axes[0].tick_params(axis='x', rotation=0)

# 2. Internet Access
```



```


df.groupby('internet_access')['final_score'].mean().plot(kind='bar', ax=axes[1],
color=['#FF9999','#66FF99'], edgecolor='black')
axes[1].set_title('Final Score by Internet Access')
axes[1].tick_params(axis='x', rotation=0)

# 3. Extracurricular
df.groupby('extracurricular')['final_score'].mean().plot(kind='bar', ax=axes[2],
color=['#FFD700','#DA70D6'], edgecolor='black')
axes[2].set_title('Final Score by Extracurricular')
axes[2].tick_params(axis='x', rotation=0)

plt.tight_layout()
plt.show()

```

Pada EDA yang pertama, yaitu *Comparison* atau perbandingan, di sini saya menggunakan barchart. Hasil output dari kode di atas beserta insight yang didapatkan adalah sebagai berikut:



Gambar 2. 18 Comparison (Perbandingan)

Ketiga grafik batang menampilkan rata-rata nilai akhir berdasarkan gender, akses internet, dan keikutsertaan ekstrakurikuler. Dari ketiga faktor tersebut, tidak ada satu pun yang menunjukkan perbedaan berarti antar kategorinya, seluruh batang berada di kisaran nilai yang hampir sama, sekitar 55–57.

- Gender: Siswa laki-laki dan perempuan memiliki rata-rata nilai akhir yang hampir identik. Artinya, gender tidak menjadi faktor pembeda performa akademik dalam dataset ini.
- Akses Internet: Siswa dengan dan tanpa akses internet menunjukkan rata-rata nilai yang setara. Ketersediaan internet tidak terbukti memberikan keunggulan akademik yang signifikan.


- Ekstrakurikuler: Siswa yang mengikuti ekstrakurikuler maupun yang tidak memiliki rata-rata nilai yang relatif sama, mengindikasikan bahwa keikutsertaan ekstrakurikuler tidak mengganggu maupun meningkatkan performa secara berarti.

Ketiga faktor kategorikal ini, yaitu gender, akses internet, dan ekstrakurikuler bukan merupakan faktor penentu performa akademik siswa. Fokus analisis sebaiknya diarahkan ke variabel lain yang lebih berpengaruh, seperti jam belajar per minggu.

2.4.2 Composition (Komposisi)

```
passed = df['passed'].value_counts()
passed_resp = passed.head(4)
plt.figure(figsize=(8, 6))
passed_resp.plot(kind='pie', autopct='%1.1f%%', startangle=140,
colors=plt.cm.Paired.colors)
plt.title('Proporsi Siswa Lulus dan Tidak Lulus')
plt.ylabel("")
plt.axis('equal')
plt.show()
```

Untuk EDA yang kedua, yaitu *Composition* atau komposisi, di sini saya menggunakan pie chart. Hasil output dari kode di atas beserta insight yang saya dapatkan adalah sebagai berikut:




Gambar 2. 19 Composition (Komposisi)

Pie chart menunjukkan bahwa 64,6% siswa dinyatakan lulus dan 35,4% tidak lulus. Meskipun mayoritas siswa berhasil lulus, proporsi siswa yang tidak lulus sebesar 35,4% terbilang cukup besar dan tidak bisa diabaikan. Hampir 1 dari 3 siswa gagal mencapai kelulusan, yang mengindikasikan masih adanya kesenjangan performa yang perlu ditangani. Temuan ini memperkuat urgensi untuk mengidentifikasi faktor-faktor yang membedakan siswa lulus dan tidak lulus yang dalam analisis ini mengerucut pada intensitas belajar sebagai variabel paling dominan.

2.4.3 Distribution (Distribusi)

```
plt.figure(figsize=(10, 6))
sns.histplot(df['final_score'], bins=20, kde=True)
plt.title('Distribusi Final Score')
plt.xlabel('Jumlah Kafein (mg)')
plt.ylabel('Frekuensi')
plt.show()
```

Pada EDA yang ketiga, yaitu *Distribution* atau distribusi, di sini saya menggunakan Histogram untuk melihat distribusi nilai akhir siswa. Untuk output kode dan insight yang saya dapatkan adalah sebagai berikut:



Gambar 2. 20 Distribution (Distribusi)


Distribusi final score mendekati distribusi normal (simetris), dengan puncak di sekitar nilai 55-60. Tidak terdapat kemiringan (skewness) ekstrem, yang

mengindikasikan bahwa nilai siswa tersebar cukup merata tanpa ada pengelompokan yang mencolok di sisi rendah maupun tinggi.

2.4.4 Relationship (Hubungan)

```
plt.figure(figsize=(8, 6))
sns.heatmap(data=df[['age','study_hours_per_week','attendance_rate','previous_
score','final_score']].corr(),
            annot=True,
            cmap='coolwarm',
            fmt='.2f')
plt.title('Heatmap Korelasi')
plt.show()
```

Pada EDA yang keempat atau yang terakhir, saya menggunakan Heatmap untuk melihat angka korelasi antara numerik. Untuk hasil dari kode di atas dan insight yang saya dapatkan adalah sebagai berikut:



Gambar 2. 21 Relationship (Hubungan)

Kolom study_hours_per_week memiliki korelasi 0,80 dengan final_score, ini merupakan angka korelasi tertinggi dan paling dominan yang berarti sekitar 64%

variasi nilai akhir dapat dijelaskan oleh jam belajar per minggu saja. Sebaliknya, usia (age) hampir tidak memiliki hubungan dengan nilai akhir.

BAB III

PENUTUP

3.1 Kesimpulan

Berdasarkan hasil Exploratory Data Analysis (EDA) yang dilakukan terhadap dataset performa akademik 500 siswa, diperoleh sejumlah temuan penting mengenai faktor-faktor yang memengaruhi nilai akhir dan status kelulusan. Dari seluruh variabel yang dianalisis, jam belajar per minggu terbukti menjadi faktor paling dominan dengan korelasi sebesar 0,80 terhadap nilai akhir, sementara tingkat kehadiran dan nilai sebelumnya juga menunjukkan kontribusi yang relevan. Sebaliknya, faktor gender, akses internet, dan keikutsertaan ekstrakurikuler tidak terbukti memberikan pengaruh yang signifikan terhadap performa akademik siswa.

Distribusi nilai akhir mendekati normal dengan proporsi siswa tidak lulus sebesar 35,4%, angka yang cukup besar dan perlu mendapat perhatian. Dataset secara keseluruhan dinyatakan bersih tanpa duplikat maupun outlier, dengan penanganan missing values pada kolom `parent_education` melalui imputasi kategori "Unknown". Analisis ini menegaskan bahwa kebiasaan belajar yang konsisten merupakan faktor kunci penentu keberhasilan akademik siswa.

3.2 Saran

Berdasarkan hasil analisis yang telah dilakukan, berikut beberapa saran yang dapat dijadikan pertimbangan ke depannya.

- Perlu dirancang program pendampingan belajar yang terstruktur, seperti jadwal belajar terbimbing atau kelompok belajar, guna meningkatkan intensitas belajar siswa yang masih rendah.
- Pemantauan tingkat kehadiran secara berkala perlu dilakukan sebagai deteksi dini bagi siswa yang berisiko mengalami penurunan performa akademik.
- Pengumpulan data pada penelitian selanjutnya sebaiknya memastikan kelengkapan informasi di seluruh kolom, terutama pada variabel yang berpotensi relevan seperti latar belakang pendidikan orang tua, guna menghindari bias analisis akibat missing values yang cukup substansial.
- Cakupan variabel perlu diperluas dengan memasukkan aspek psikologis siswa seperti motivasi belajar, tingkat stres, dan kondisi kesehatan mental untuk mendapatkan gambaran yang lebih komprehensif mengenai faktor-faktor yang memengaruhi performa akademik.

- Penerapan metode analisis lanjutan seperti regresi atau klasifikasi berbasis machine learning dapat dipertimbangkan untuk membangun model prediksi kelulusan yang lebih akurat dan dapat diterapkan secara praktis.